République du Sénégal

Un Peuple – Un But – Une Foi

Ministère l'enseignement supérieur de la recherche et de l'innovation

Ecole Polytechnique de Thiès

B.P.A 10 Thiès

Tel: (221) 76 223 61 74 – Fax: (221) 33 951 14 67

Speech Emotion Recognition

Par Salimata Diagana et Ndeye Awa Salane

Rapport de projet de Machine Learning

Écrit le 26 Juin 2022

DIC 1 - Génie Informatique et Télécommunications

2021

Devant un jury composé de / Professeur responsable:

Ndeye Fatou Ngom Diop, Prof. EPT, Dr

Table des matière

Abstract **1**

Historique **2**

Définition 2

Recherches sur le domaine 3

Pourquoi la reconnaissance des émotions ? 3

Acquisition des données **4**

Obstacles majeurs 4

Exploration des données 4

I- Ryerson Audio-Visual Database of Emotional Speech and Song (RAVDESS) 5

II- Surrey Audio-Visual Expressed Emotion (SAVEE) 5

III- Toronto Emotional Speech Set (TESS) 5

Caractéristiques de l'audio : Mel-frequency Cepstral Coefficient (MFCC) 6

Algorithmes de Machine Learning **8**

Workflow 8

Matrices de confusion 10

Application **11**

Perspectives 12

Références **13**

Abstract

En tant qu'êtres humains, la parole est l'un des moyens les plus naturels de s'exprimer. Les émotions jouant un rôle vital dans la communication, leur détection et leur analyse sont d'une importance vitale dans le monde numérique actuel de la communication à distance. Reconnaître les émotions humaines a toujours été une tâche fascinante pour les data scientists. Néanmoins la détection des émotions est une tâche difficile, car les émotions sont subjectives. Il n'y a pas de consensus sur la façon de les mesurer ou de les catégoriser.

Notre processus de construction de modèles qui classent les audios dans l'une des seize classes (homme/femme et huit émotions différentes) est décrit plus en détail ci-dessous.

Historique

La communication avec les machines informatiques est devenue de plus en plus « bavarde » ces jours-ci : Alexa, Cortana, Siri et de nombreux autres systèmes de dialogue ont frappé le marché des consommateurs sur une base plus large que jamais, mais l'un d'entre eux remarque-t-il vraiment nos émotions et y réagit-il comme un interlocuteur humain le ferait ?

Définition

La reconnaissance des émotions est le processus d'identification des émotions humaines. Les gens varient considérablement dans leur précision à reconnaître les émotions des autres. L'utilisation de la technologie pour aider les personnes à reconnaître leurs émotions est un domaine de recherche relativement naissant. Généralement, la technologie fonctionne mieux si elle utilise plusieurs modalités en contexte. À ce jour, la plupart des travaux ont été menés sur l'automatisation de la reconnaissance des expressions faciales à partir de la vidéo, des expressions parlées à partir de l'audio, des expressions écrites à partir du texte et de la physiologie mesurée par les appareils portables.
Comme le montre le titre, Speech Emotion Recognition (SER) est un système capable d'identifier l'émotion de différents échantillons audio. D'après la description, cette tâche est similaire à l'analyse des sentiments textuels, et les deux partagent également certaines applications car elles ne diffèrent que par la modalité des données - texte par rapport à l'audio. Comme l'analyse des sentiments, vous pouvez utiliser la reconnaissance des émotions de la parole pour

trouver la gamme émotionnelle ou la valeur sentimentale dans divers enregistrements audio tels que les entretiens d'embauche, les appels de l'appelant, les vidéos en streaming et les chansons. De plus, même les systèmes de recommandation ou de classification musicale peuvent regrouper les chansons en fonction de leur humeur et recommander des listes de lecture organisées à l'utilisateur. Il est prudent de supposer que les algorithmes complexes de Spotify et YouTube ont également un composant SER qui aide dans les recommandations musicales.

Recherches sur le domaine

En fait, la discipline de reconnaissance automatique des émotions humaines et des états affectifs à partir de la parole, généralement appelée reconnaissance des émotions de la parole ou SER en abrégé, a désormais dépassé «l'âge de la majorité», célébrant le 22e anniversaire après le travail fondateur de Daellert et Waibel en 1996, sans doute le premier document de recherche sur le sujet. Cependant, l'idée existe depuis encore plus longtemps puisque le premier brevet date de la fin des années 1970.

Pourquoi la reconnaissance des émotions ?

L'un de ses principaux objectifs sera d'améliorer les interactions humain-ordinateur pour une meilleure expérience utilisateur.

"Nos ordinateurs vont pouvoir gérer automatiquement les ambiances et la luminosité en fonction de nos humeurs, et adapter leur comportement selon notre état. Ils sauront être conciliants s'ils nous voient en colère, ou stimulants s'ils nous jugent atones " Axel Boidin.

Les applications de reconnaissance vocale simple sont répandues - sous-titres générés automatiquement par YouTube, transcriptions de discours en direct, transcriptions de cours en ligne et chatbots intelligents à assistance vocale comme Alexa et Siri. Pour cette raison, des recherches très spécialisées ont donné des résultats lucratifs et fructueux - les sous-titres générés automatiquement par YouTube s'améliorent chaque année. Cependant, les applications de la reconnaissance des émotions de la parole sont plus nuancées et ajoutent une nouvelle dimension à l'utilisation de l'IA et comment elle peut nous faciliter la vie pour les améliorer.

Une application très récente de SER a émergé de l'augmentation soudaine de l'apprentissage en ligne où les éducateurs peuvent observer la réponse d'un élève en classe et mettre en évidence des pointeurs qui pourraient les aider à aider l'éducation de l'élève. Une autre utilisation à venir est d'évaluer les candidats postulant à des postes de direction en analysant leurs réponses lors d'entretiens audio ou vidéo. Leur confiance ou leurs appréhensions peuvent être mesurées quantitativement pour la première fois à l'aide du SER, et ainsi les responsables du recrutement peuvent sélectionner le candidat qui correspond le mieux.

D'autre part, le SER peut aider à évaluer les performances des employés existants, en particulier dans le secteur des centres d'appels, où une conversation inappropriée avec un client peut être désastreuse pour l'image de l'entreprise. De tels systèmes peuvent également aider à traiter les réclamations des clients plus efficacement et même automatiquement. De même, la santé émotionnelle de l'employé peut également être suivie et prise en charge.

Acquisition des données

Obstacles majeurs

- Les émotions sont subjectives, les gens les interprètent différemment. Il est difficile de définir la notion d'émotions.
- Annoter un enregistrement audio est un défi. Combien d'émotions devrions-nous définir pour la reconnaissance ?
- La collecte de données est complexe. De nombreuses données audio peuvent être obtenues à partir de films ou d'actualités. Cependant, les deux sont biaisés car les reportages doivent être neutres et les émotions des acteurs sont imitées. Il est difficile de rechercher un enregistrement audio neutre sans aucun parti pris.

Exploration des données

Nos données proviennent de 3 datasets: RAVDESS, SAVEE et TESS.

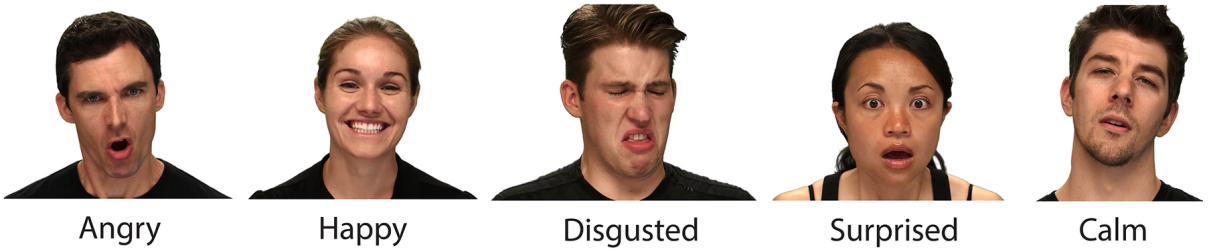

I- Ryerson Audio-Visual Database of Emotional Speech and Song (RAVDESS)

La Ryerson Audio-Visual Database of Emotional Speech and Song (RAVDESS) contient 7356 fichiers (taille totale : 24,8 Go). La base de données contient 24 acteurs professionnels (12 femmes, 12 hommes), vocalisant deux phrases semblables dans un accent nord-américain neutre. Le discours comprend des expressions de calme, de joie, de tristesse, de colère, de peur, de surprise et de dégoût. Chaque expression est produite à deux niveaux d'intensité émotionnelle (normal, fort), avec une expression neutre supplémentaire. Toutes les conditions sont disponibles dans trois formats de modalité : audio uniquement (16 bits, 48 kHz .wav), audio-vidéo (720p H.264, AAC 48 kHz, .mp4) et vidéo uniquement (pas de son).

II- Surrey Audio-Visual Expressed Emotion (SAVEE)

La base de données SAVEE a été enregistrée auprès de quatre locuteurs masculins anglais natifs (identifiés comme DC, JE, JK, KL), étudiants de troisième cycle et chercheurs de l'Université de Surrey et âgés entre 27 à 31 ans. L'émotion a été décrite en catégories discrètes : colère, dégoût, peur, bonheur, tristesse et surprise. Ceci se base sur les études interculturelles d'Ekman et les études sur la reconnaissance automatique des émotions. Ils ont ajouté neutre pour fournir des enregistrements de 7 catégories d'émotions. Le matériel textuel consistait en 15 phrases TIMIT par émotion : 3 phrases communes, 2 spécifiques à une émotion et 10 phrases génériques qui étaient différentes pour chaque émotion et phonétiquement équilibrées. Les 3 phrases communes et 2 × 6 = 12 phrases spécifiques aux émotions ont été enregistrées comme neutres pour donner 30 phrases neutres.

III- Toronto Emotional Speech Set (TESS)

Deux actrices (âgées de 26 et 64 ans) prononcent un ensemble de 200 mots cibles dans la phrase porteuse « Say the word _____ » et enregistrent un ensemble d'audios représentant chacune des sept émotions (la colère, le dégoût, la peur, le bonheur, l'agréable surprise, tristesse et neutre). Il y a 2800 audios au total. Les deux actrices ont été recrutées dans la région de Toronto. Les deux actrices parlent l'anglais comme première langue, ont fait des études universitaires et ont une formation musicale. Les tests audiométriques ont indiqué que les deux actrices ont des seuils dans la plage normale.

Caractéristiques de l'audio : Mel-frequency Cepstral Coefficient (MFCC)

Commençons par développer l'acronyme MFCC — Mel Frequency Cepstral Coefficients.
Tout d'abord le mot cepstral c'est spectral avec la spec inversée ! Pourquoi cependant? Pour une compréhension très basique, cepstre est l'information du taux de changement dans les bandes spectrales. Dans l'analyse conventionnelle des signaux temporels, toute composante périodique (par exemple, les échos) apparaît sous forme de pics nets dans le spectre de fréquence correspondant (c'est-à-dire le spectre de Fourier. Ceci est obtenu en appliquant une transformée de Fourier sur le signal temporel). Ceci peut être vu dans l'image suivante :

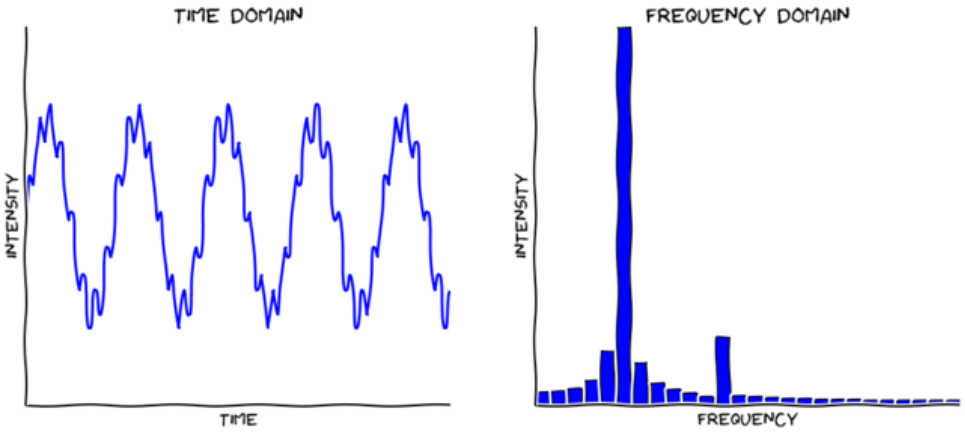

En prenant le logarithme de la magnitude de ce spectre de Fourier, puis en prenant à nouveau le spectre de ce logarithme par une transformation en cosinus , nous observons un pic partout où il y a un élément périodique dans le signal temporel d'origine. Puisque nous appliquons une transformée sur le spectre de fréquence lui-même, le spectre résultant n'est ni dans le domaine fréquentiel ni

dans le domaine temporel et donc Bogert et al . a décidé de l'appeler le domaine quefrency . Et ce spectre du logarithme du spectre du signal horaire a été nommé cepstre.

L'image suivante est un résumé des étapes expliquées ci-dessus:

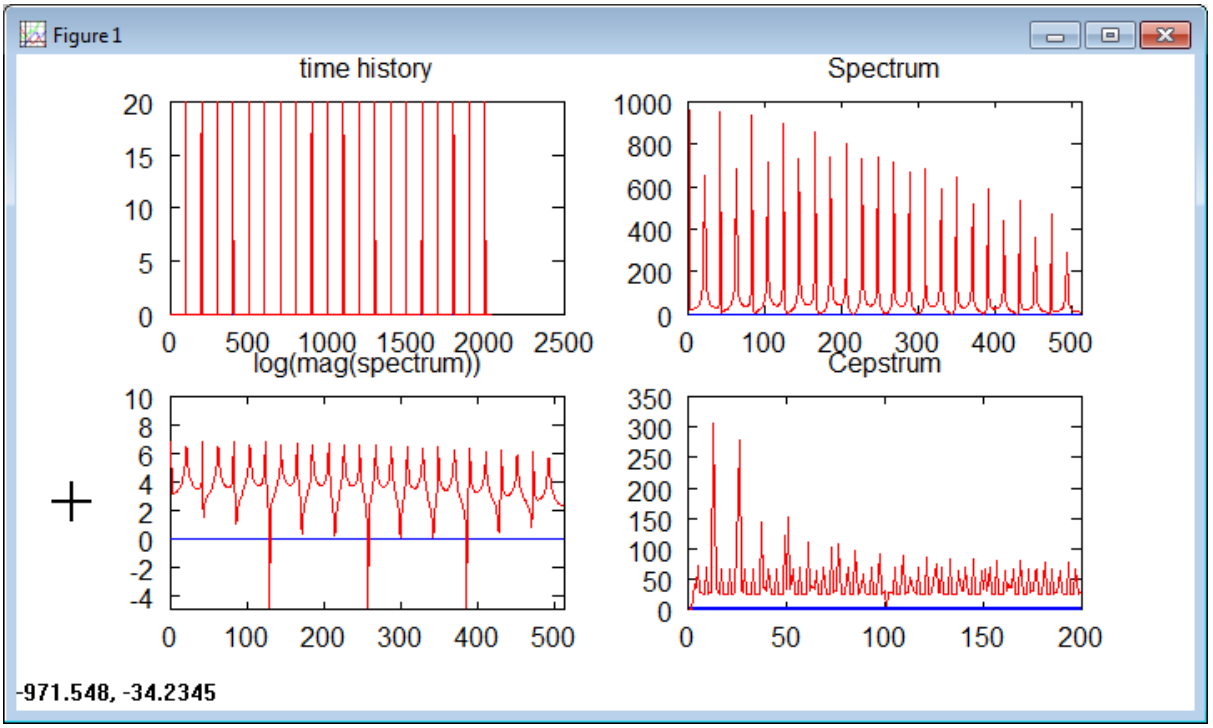

La hauteur est l'une des caractéristiques d'un signal vocal et est mesurée comme la fréquence du signal. *L'échelle Mel* est une échelle qui relie la fréquence perçue d'une tonalité à la fréquence réelle mesurée. Il met à l'échelle la fréquence afin de correspondre plus étroitement à ce que l'oreille humaine peut entendre (les humains sont mieux à même d'identifier de petits changements dans la parole à des fréquences plus basses). Cette échelle a été dérivée d'ensembles d'expériences sur des sujets humains.
La gamme de l'audition humaine est de 20 Hz à 20 kHz. Imaginez une mélodie à 300 Hz. Cela ressemblerait à la tonalité standard d'un téléphone fixe. Imaginez maintenant une mélodie à 400 Hz (une tonalité de numérotation un peu plus aiguë). Maintenant, comparez la distance entre ces deux, quelle que soit la façon dont cela peut être perçu par votre cerveau. Imaginez maintenant un signal de 900 Hz (similaire à un son de rétroaction de microphone) et un son de 1 kHz. La distance perçue entre ces deux sons peut sembler supérieure aux deux premiers bien que la différence réelle soit la même (100Hz). L'échelle Mel essaie de saisir ces différences. Une fréquence mesurée en Hertz (f) peut être convertie en échelle Mel en utilisant la formule suivante :

$$\mathrm{Mel}(f) = 2595 \log\left(1 + \frac{f}{700}\right)$$

Le schéma fonctionnel suivant est un résumé par étapes de la façon dont nous sommes arrivés aux MFCC :

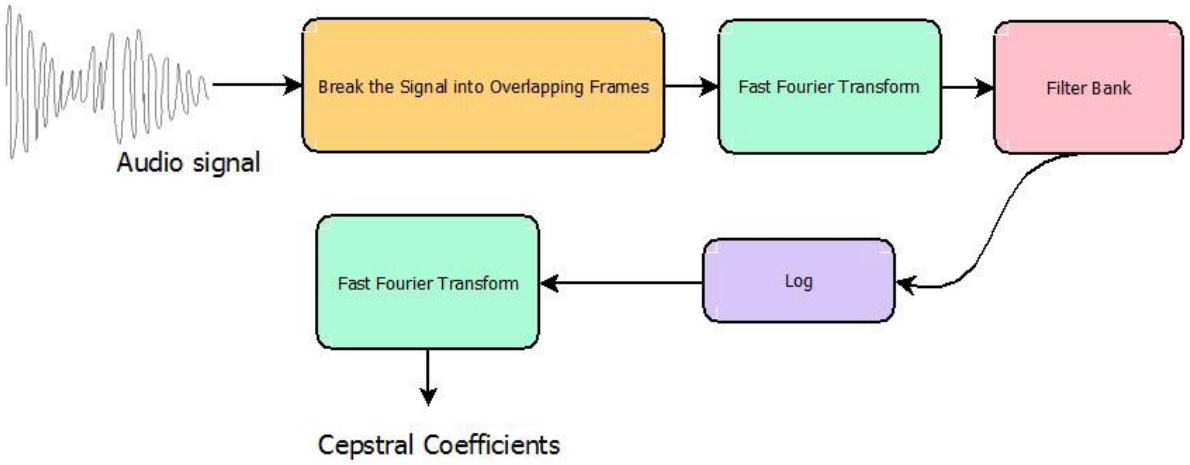

Ici, Filter Bank fait référence aux filtres mel (conversion à l'échelle mel) et les coefficients cepstraux ne sont rien d'autre que des MFCC.

Algorithmes de Machine Learning

Workflow

Notre approche pour classer la parole en émotion était la suivante :

1. Lire les fichiers WAV en utilisant le package libROSA en Python
2. Extraire les caractéristiques de la série temporelle audio créée par libROSA à l'aide des fonctions du package libROSA (spectrogrammes MFCC).
3. Construire une série de modèles à partir du package scikit-learn.
4. Construire un modèle d'ensemble utilisant un classificateur de vote rigide pour améliorer les performances.

Nous avons eu à tester 3 algorithmes : SVM, Forêts aléatoires et Voting Classifier (voir notebook Jupyter ci-joint)

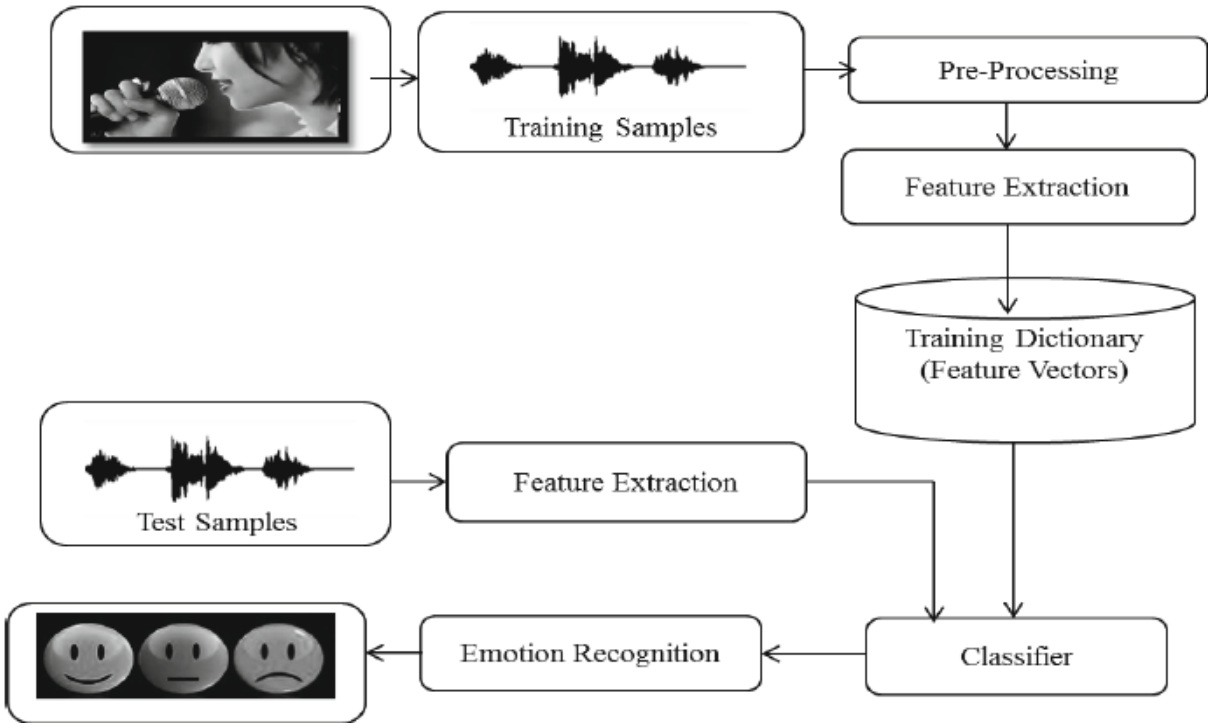

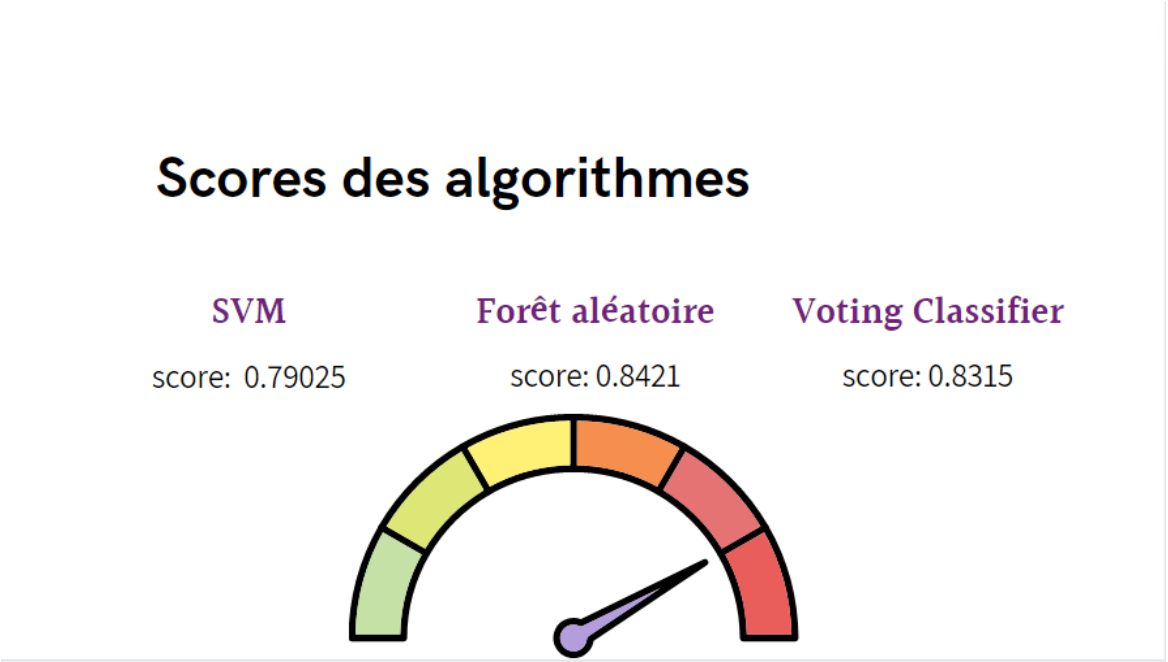

Matrices de confusion

classification selon l'émotion et le genre :

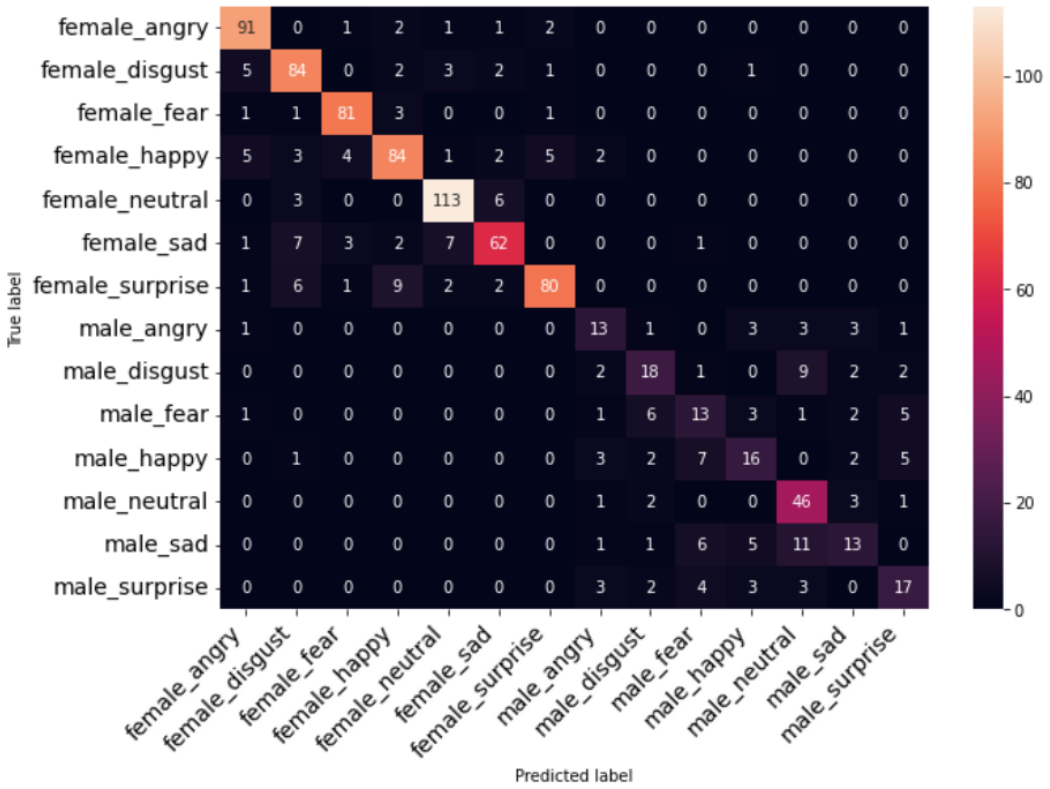

Classification selon le genre :

```
0.9925847457627118
```

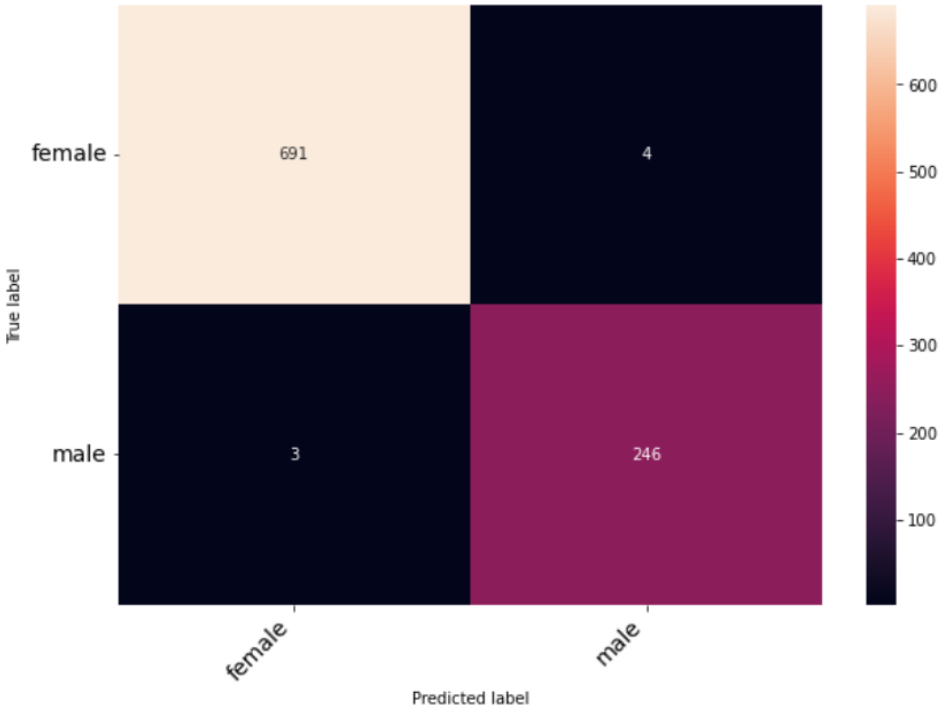

Classification selon l'émotion :

```
0.7754237288135594
```

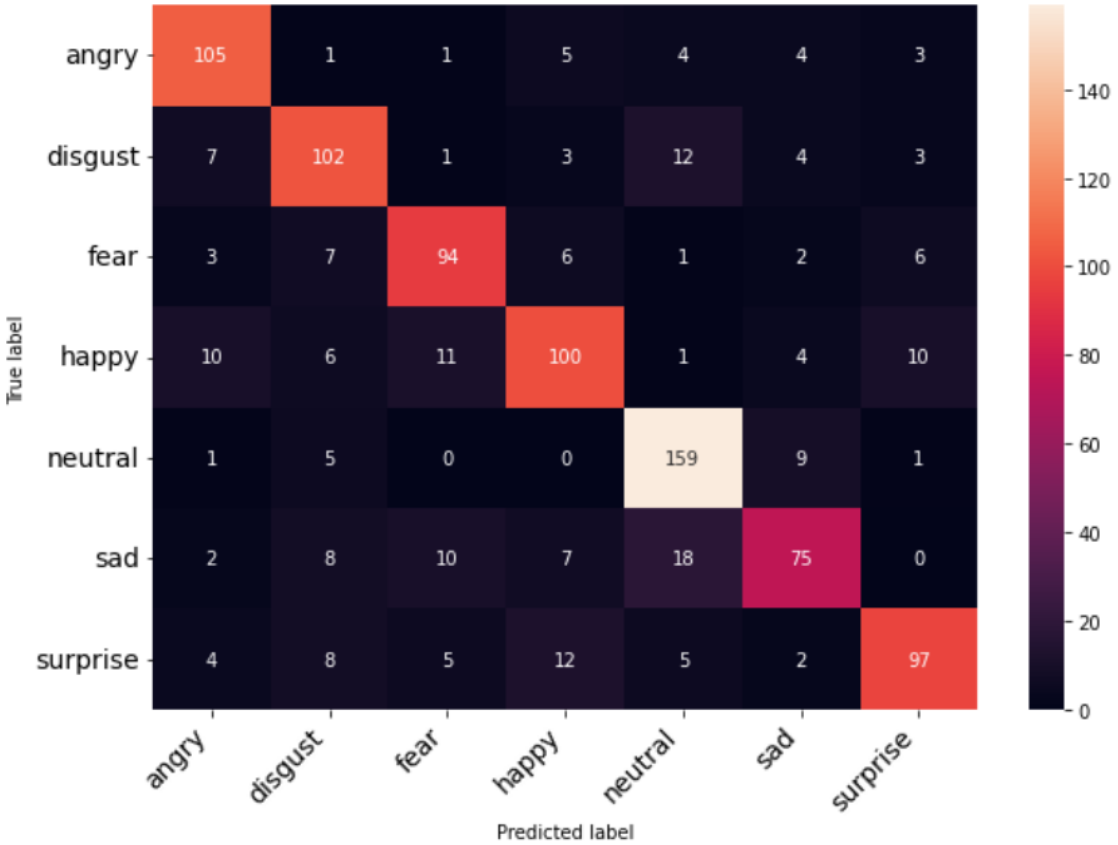

Application

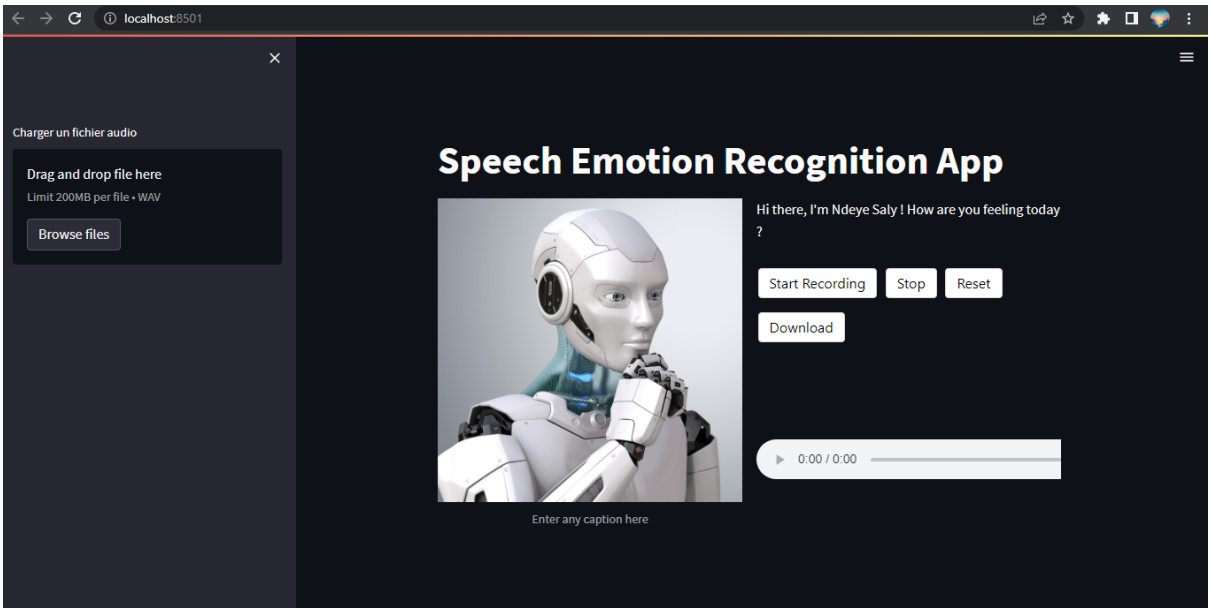

Notre application pour ce projet consiste en une Speech Emotion Recognition System. L'agent Ndeye Saly fait office de thérapiste. Après une salutation, elle demandera à l'utilisateur son état actuel. Dépendant de l'émotion véhiculée dans le fichier wav, le robot prédit cette dernière et propose de suite une citation ou proverbe. Cette citation ira dans le sens de calmer l'utilisateur s'il est en colère par exemple, de le stimuler s'il est triste ou dépressif ou encore de le rendre plus heureux s'il est déjà...
Notre modele confond parfois le genre, du fait d'après notre constat que dans le jeu de données TESS, la femme agée a une voix quasi rauque (ressemblant à celle d'un homme).
Aussi, la fonctionnalité qui consiste à traiter directement l'audio enregistré via l'interface et faire la prédiction n'est pas encore disponible sur Streamlit. Il faut ainsi après l'avoir enregistré, le télécharger dans l'ordinateur, le charger pour enfin le soumettre à Ndeye Saly.

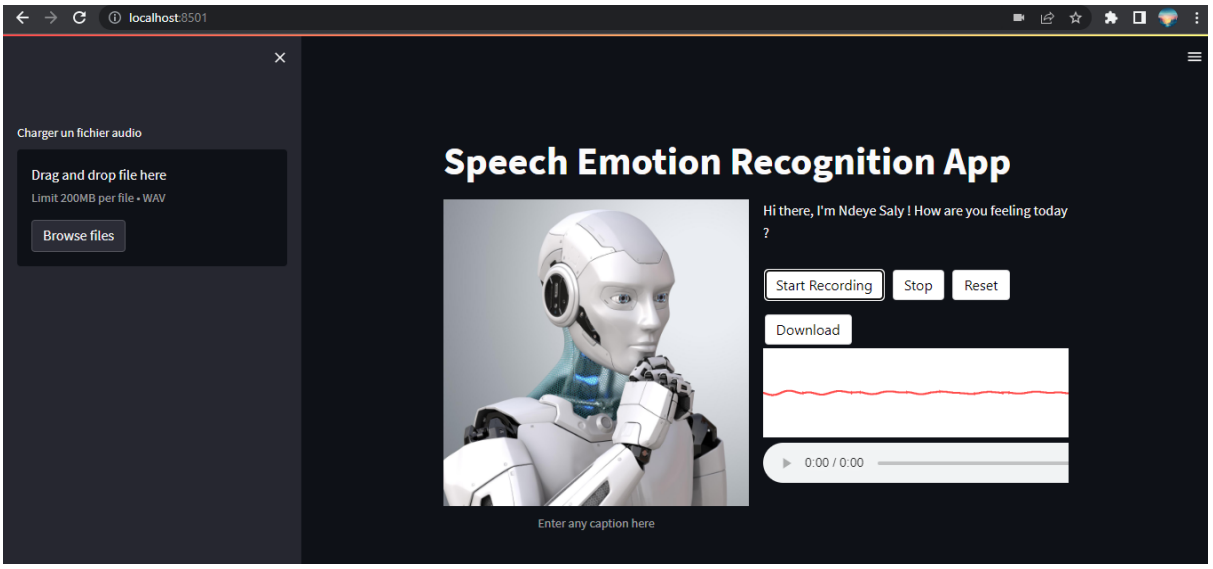

Perspectives

- Utiliser du Deep Learning
- Inclure du Face Emotion Recognition
- Inclure du NLP
- Inclure du Robot Counseling

Références

- Livingstone, Steven R., and Frank A. Russo. "The Ryerson Audio-Visual Database of Emotional Speech and Song (RAVDESS)." *Zenodo*, Zenodo, 5 Apr. 2018, zenodo.org/record/1188976#.YriYSnbP1PZ. Accessed 26 June 2022.
- "Surrey Audio-Visual Expressed Emotion (SAVEE) Database." *Kahlan.eps.surrey.ac.uk*, kahlan.eps.surrey.ac.uk/savee/Database.html
- "Toronto Emotional Speech Set (TESS) | TSpace Repository." *Tspace.library.utoronto.ca*, tspace.library.utoronto.ca/handle/1807/24487
- Nair, Pratheeksha. "The Dummy's Guide to MFCC." *Prathena*, 27 July 2018, medium.com/prathena/the-dummys-guide-to-mfcc-aceab2450fd.
- "Audio Emotion | Part 1 - Explore Data." *Kaggle.com*, www.kaggle.com/code/ejlok1/audio-emotion-part-1-explore-data. Accessed 26 June 2022.
- https://www.analyticsinsight.net/speech-emotion-recognition-ser-through-machine-learning/
- https://www.kaggle.com/datasets/uwrfkaggler/ravdess-emotional-speech-audio
- https://www.kaggle.com/datasets/ejlok1/toronto-emotional-speech-set-tess
- https://www.kaggle.com/datasets/ejlok1/surrey-audiovisual-expressed-emotion-savee
- Nair, Pratheeksha. "The Dummy's Guide to MFCC." Prathena, 27 July 2018, medium.com/prathena/the-dummys-guide-to-mfcc-aceab2450fd.